

# Introduction

Dans le cadre de ce travail, nous explorons une activité populaire : la collection de vignettes. Cette activité consiste à rassembler un ensemble complet de vignettes uniques souvent distribuées aléatoirement dans des paquets de céréales par exemple. Notre étude se concentre sur le temps que peut mettre une personne pour compléter la collection. Combien de paquets de céréales une personne doit-elle acheter pour terminer sa collection de  $N$  vignettes différentes ?

Ce sujet nous intéresse pour son lien étroit avec les concepts mathématiques, en particulier la théorie des probabilités. En analysant les probabilités d'obtenir des vignettes déjà possédées ou nouvelles à chaque achat de paquet de céréales, en supposant que la personne achète 1 paquet par semaine, nous cherchons à établir des estimations théoriques pour le nombre moyen de paquets nécessaires pour achever la collection et donc la notion d'espérances rentrera en jeu.

En outre, nous avons examiné des situations plus complexes, comme les échanges de doublons avec d'autres collectionneurs ou les offres spéciales des fabricants permettant l'acquisition de vignettes spécifiques en échange d'un certain nombre de vignettes (par exemple 10 vignettes contre 1 vignette spécifique). Il est clair que ces éléments vont influencer au niveau du temps de collecte des vignettes et c'est ce que nous allons démontrer durant notre étude.

L'objectif principal de notre étude est donc de développer un modèle mathématique solide pour estimer le temps moyen nécessaire à un collectionneur pour finaliser sa collection de vignettes. Nous analysons également diverses stratégies et conditions qui pourraient affecter ce temps.

Au fil de ce rapport, nous présentons notre approche mathématique, discutons des résultats théoriques obtenus à l'aide des lois de probabilités usuelles et analysons différentes situations pour mieux comprendre le problème du collectionneur de vignettes. Pour cela, nous avons réalisé un programme informatique en C++ et nous avons fait plusieurs simulations à l'aide de RStudio.

~~Enfin~~, les différents codes sont disponibles en annexe, à la fin du document.

# Modèle de base

## 2.1 Étude théorique

Lorsque l'on suppose que toutes les vignettes sont équiprobables, c'est-à-dire que chaque type de vignette a une probabilité de  $\frac{1}{n}$  d'être obtenu lors de l'achat d'une boîte, on peut étudier la durée nécessaire pour compléter une collection de vignettes.

Soit  $T$  la variable aléatoire qui représente le nombre de paquets à acheter (et par extension, le nombre de semaines nécessaires) pour compléter la collection de vignettes.

L'obtention d'une nouvelle vignette dans un paquet  $k$  suit une loi géométrique de paramètre  $p = \frac{n-(k-1)}{n}$ , où  $n$  est le nombre total de vignettes à collecter. Ainsi,  $T_{n,k}$ , une variable aléatoire représentant le nombre de paquets à acheter pour obtenir une nouvelle vignette lorsque vous en avez déjà  $k$  différentes, suit également une loi géométrique de paramètre  $p$ .

L'espérance de  $T_{n,k}$  est donnée par :  $E(T_{n,k}) = \frac{1}{p} = \frac{n}{n-(k-1)}$

Par conséquent, la variable aléatoire  $T$  qui représente le temps nécessaire pour compléter la collection entière est la somme de toutes les  $T_{n,k}$  où  $k$  varie de 1 à  $n$ ,

$$T = \sum_{k=1}^n T_{n,k}$$

En utilisant la linéarité de l'espérance, l'espérance de  $T$  est :

$$\begin{aligned} E(T_n) &= \sum_{k=1}^n E(T_{n,k}) \\ &= \sum_{k=1}^n \frac{n}{n-(k-1)} \\ &= n \left( \frac{1}{n} + \frac{1}{n-1} + \frac{1}{n-2} + \dots + \frac{1}{2} + \frac{1}{1} \right) \\ &= n \cdot \left( 1 + \frac{1}{2} + \dots + \frac{1}{n-2} + \frac{1}{n-1} + \frac{1}{n} \right) \\ &= n \cdot \sum_{k=1}^n \frac{1}{k} \end{aligned}$$

~~On~~ En notant  $H_n$  le  $n$ -ième nombre harmonique ;  
 $E(T_n) = n \cdot H_n$

En utilisant le développement asymptotique de  $H_n$ , on obtient :

$$E(T_n) = n \cdot H_n = n \cdot \ln(n) + \gamma \cdot n + \frac{1}{2} + o(1)$$

Où  $\gamma \approx 0.5772156649$  est la constante d'Euler-Mascheroni.[1]

enlever les points de multiplication?

## 2.2 Simulations

### 2.2.1 Simulation en c++

Les simulations Monte Carlo [2] sont utilisées pour trouver des solutions (approximatives) à des problèmes de probabilité, surtout en inférence statistique lorsque des solutions exactes ne sont pas connues ou sont très difficiles à calculer. Le problème du collectionneur de vignettes, tel que nous le nommons, est particulièrement adapté à cela.

*compléter* La solution Monte Carlo est simplement un algorithme : nous simulons un certain nombre de paquets de céréales dans lesquels des vignettes sont présentes et comptons combien de paquets sont nécessaires pour compléter une collection séquentiellement. Après avoir répété cette procédure un certain nombre de fois, on calcule simplement la moyenne du nombre de paquets nécessaires pour remplir les albums. Pour ce faire, nous avons codé en langage C++ et nous avons réalisé les courbes à l'aide du logiciel Rstudio.

L'algorithme doit reproduire les conditions décrites dans le problème : ici, l'album comporte par exemple 500 vignettes, chaque paquet contient d'abord 1 vignette pour le cas simple puis nous verrons avec 5 vignettes distinctes, et les vignettes seront considérées comme réparties uniformément parmi les paquets. Ses étapes sont les suivantes :

1. Nous avons créé un tableau avec les numéros des vignettes que nous possédons. Au départ, sa longueur est de zéro.
2. Nous avons pris  $k = 1$  où  $k$  est le nombre de paquets.
3. Nous avons simulé un paquet en prenant un échantillon de taille 1, sans remplacement, à partir d'une urne contenant 500 balles numérotées de 1 à 500.
4. Nous avons vérifié la vignette dans le paquet de l'étape 3 par rapport à celles dans le tableau de l'étape 1 et nous avons inclus toute vignette qui n'est pas encore présente. Nous supprimons les vignettes que nous possédons déjà.
5. Si le tableau a une longueur de 500, alors on arrête. Sinon, on incrémente  $k$  de un et on retourne à l'étape 3.

En exécutant notre programme, voici ce qu'on obtient :

Dans un premier temps, nous entrons nos différentes valeurs (voir Figure 1 1).

```
Entrez nombre de vignettes de votre collection (0 pour arreter programme)
Ici > 500
Entrez nombre de simulations (0 pour arreter programme)
Ici > 1000
Entrez nombre de vignettes (0 pour arreter programme)
Ici > 5
```

FIGURE 1 – Entrée valeurs simulation

Voici les résultats obtenus (voir les figures 2) :

```
-Simulation :
>> Il faut en moyenne 3402.73 semaines pour completer la collection de 500 vignettes sans echange.
>> Il faut en moyenne 685.576 semaines pour completer la collection de 500 vignettes avec 5 dans la boite de cereales
```

FIGURE 2 – Résultats de la simulation

```
-Valeur theorique :
>> Il faut en moyenne 3396.41 semaines pour completer la collection de 500 vignettes sans echange a l'aide de la formule
theorique n*somme(1/k).
>> Il faut en moyenne 3396.41 semaines pour completer la collection de 500 vignettes sans echange a l'aide de l'approxim
ation de la formule theorique.
```

FIGURE 3 – Résultats théoriques

Soit  $T$  la variable aléatoire représentant le nombre de paquets nécessaires pour compléter la collection. Nous nous intéressons à la valeur attendue de  $T$ , donc nous répétons simplement la procédure ci-dessus pour un grand nombre d'albums et prenons la moyenne arithmétique des valeurs finales de  $k$ . À titre d'exemple, nous avons exécuté l'algorithme pour 1000 "albums" et avons obtenu 3482,73 comme estimation du nombre attendu de paquets nécessaires pour compléter un album avec 1 vignette dans un paquet. Il convient de souligner que, en tant qu'approximation stochastique, l'algorithme donne généralement une réponse différente à chaque exécution (la réponse 3483 mentionnée précédemment vient de l'arrondi à l'entier supérieur de 3482,73). En comparant cela à la valeur théorique qui de 3397 en prenant l'arrondi supérieur (voir Figure 3), on voit une petite différence.

*plus de tirages  $\Rightarrow$  estimation plus précise*

Et pour la simulation avec 5 vignettes dans un paquet, ~~nécessairement~~, le temps de collecte diminue (voir Figure 2).

## 2.2.2 courbe sous Rstudio

Nous avons réalisé une simulation du problème du collectionneur de vignettes en modélisant le processus d'achat de paquets de céréales. Nous avons suivi l'évolution du nombre de vignettes collectées au fil du temps, et les résultats ont été représentés graphiquement.




FIGURE 4 – Évolution du nombre de vignettes collectées au fil du temps




FIGURE 5 – Zoom

La Figure 4 illustre l'évolution du nombre de vignettes collectées en fonction du temps. A noter que dans cet exemple, il n'y a qu'une vignette dans le paquet de céréale. Nous pouvons tirer plusieurs observations et conclusions à partir de cette représentation graphique.

Tout d'abord, l'ascension initiale de la courbe indique une phase où de nombreuses vignettes uniques sont collectées rapidement au début de la période d'achat. Cela reflète la probabilité élevée d'obtenir des vignettes manquantes au début de la collection.

Ensuite, au fur et à mesure que le temps progresse, la courbe présente une pente moins prononcée, indiquant que la collecte de nouvelles vignettes devient plus lente. Cela pourrait correspondre à la phase où le collectionneur commence à accumuler des vignettes en double et trouve moins fréquemment de nouvelles vignettes.

Nous remarquons par ailleurs que la courbe est de la forme  $n \cdot H_n$ .

Ces observations préliminaires nous inciteront à approfondir notre analyse, à examiner les stratégies utilisées et à comparer les résultats obtenus. Cette analyse détaillée sera présentée dans la section suivante.

## 2.3 Possibilité d'échange

### 2.3.1 Algorithme

A compléter

# Généralisation : Plusieurs vignettes

## 3.1 Etude théorique et approximation

A modifier

Dans le problème original du collectionneur de coupons, chaque paquet a une seule vignette. Ainsi, le nombre de paquets  $T$  nécessaires pour compléter la collection est une somme de variables aléatoires géométriques avec une probabilité variable de trouver une nouvelle vignette. La valeur attendue de cette variable est simplement la somme des valeurs attendues de telles variables aléatoires géométriques,

$$E(T) = n \left( 1 + \frac{1}{2} + \cdots + \frac{1}{N} \right).$$

La série à l'intérieur des parenthèses est la  $N$ -ième somme harmonique. Dans notre problème, chaque paquet a cinq vignettes différents, une approximation est  $E(T)/5$ . Quelles sont les approximations pour la somme harmonique  $N$ -ième ? Souvent, elle est approximée par  $\ln(n)$ . Cependant, une approximation différente est donnée par

$$N \left( 1 + \frac{1}{2} + \cdots + \frac{1}{n} \right) \approx n \ln(n) + \gamma n + \frac{1}{2},$$

où  $\gamma \approx 0.57721$  est la constante d'Euler-Mascheroni. Pour , cette approximation donne  $E(T)/2 \approx .$ , beaucoup plus proche des solutions trouvées ci-dessus.

Dans la suite de ce chapitre nous allons prendre le cas de deux vignettes dans le céréale comme exemple pour étude de plusieurs vignettes.

## 3.2 Simulation

### 3.2.1 Algorithme et code C++

A compléter